

سوالات و پاسخ‌های امتحان پایان‌ترم درس داده‌کاوی

دانشگاه شهید مدنی آذربایجان - نیمسال اول سال تحصیلی ۱۴۰۴-۱۴۰۵

سوال ۱

با توجه به جدول زیر مقدار شاخص جینی (Gini) و Gain Ratio را برای ویژگی credit_rating محاسبه کنید.

buys_computer Class:	credit_rating	student	income	age	RID
no	fair	no	high	youth	۱
no	excellent	no	high	youth	۲
yes	fair	no	high	middle_aged	۳
yes	fair	no	medium	senior	۴
yes	fair	yes	low	senior	۵
no	excellent	yes	low	senior	۶
yes	excellent	yes	low	middle_aged	۷
no	fair	no	medium	youth	۸
yes	fair	yes	low	youth	۹
yes	fair	yes	medium	senior	۱۰
yes	excellent	yes	medium	youth	۱۱
yes	excellent	no	medium	middle_aged	۱۲
yes	fair	yes	high	middle_aged	۱۳
no	excellent	no	medium	senior	۱۴

پاسخ:

در ابتدا آنتروپی کل دیتاست را به دست می‌آوریم. ۱۴ رکورد داریم که ۹ تای آن yes و ۵ تای آن no است، لذا آنتروپی به صورت زیر محاسبه می‌شود:

$$H(D) = -\frac{9}{14} \log_2 \left(\frac{9}{14} \right) - \frac{5}{14} \log_2 \left(\frac{5}{14} \right) = 0.9403$$

سپس Info ویژگی credit_rating را حساب می‌کنیم. این ویژگی دو مقدار fair و excellent دارد که توزیع ویژگی هدف برای هر کدام از این مقادیر به شکل زیر است:

- fair: ۸ رکورد (۶ رکورد yes و ۲ رکورد no)
- excellent: ۶ رکورد (۳ رکورد yes و ۳ رکورد no)

محاسبه آنتروپی برای هر مقدار:

$$I(6, 2) = -\frac{6}{8} \log_2 \left(\frac{6}{8} \right) - \frac{2}{8} \log_2 \left(\frac{2}{8} \right) = 0.8113$$

$$I(3, 3) = -\frac{3}{6} \log_2 \left(\frac{3}{6} \right) - \frac{3}{6} \log_2 \left(\frac{3}{6} \right) = 1.0$$

میزان اطلاعات (Info) برای این ویژگی برابر است با:

$$\begin{aligned} \text{Info}_{\text{credit_rating}}(D) &= \frac{8}{14} \times I(6, 2) + \frac{6}{14} \times I(3, 3) \\ &= \frac{8}{14}(0.8113) + \frac{6}{14}(1) = 0.8922 \end{aligned}$$

در مرحله بعد Gain را محاسبه می‌کنیم:

$$\text{Gain} = H(D) - \text{Info}_{\text{credit_rating}}(D) = 0.9403 - 0.8922 = 0.0481$$

سپس Split Info را به دست می‌آوریم:

$$\text{SplitInfo} = -\frac{8}{14} \log_2 \left(\frac{8}{14} \right) - \frac{6}{14} \log_2 \left(\frac{6}{14} \right) = 0.9852$$

و در نهایت Gain Ratio محاسبه می‌شود:

$$\text{Ratio Gain} = \frac{\text{Gain}}{\text{SplitInfo}} = \frac{0.0481}{0.9852} = 0.0488$$

محاسبه شاخص جینی (Gini):

$$\text{Gini}(D) = 1 - \left(\frac{9}{14} \right)^2 - \left(\frac{5}{14} \right)^2 = 0.459$$

$$\text{Gini}(\text{fair}) = 1 - \left(\frac{6}{8} \right)^2 - \left(\frac{2}{8} \right)^2 = 1 - \frac{36}{64} - \frac{4}{64} = \frac{24}{64} = 0.375$$

$$\text{Gini}(\text{excellent}) = 1 - \left(\frac{3}{6} \right)^2 - \left(\frac{3}{6} \right)^2 = 1 - \frac{1}{4} - \frac{1}{4} = 0.5$$

$$\text{Gini}_{\text{split}}(\text{credit_rating}) = \frac{8}{14}(0.375) + \frac{6}{14}(0.5) \approx 0.428$$

سوال ۲

با در نظر گرفتن کلاس واقعی و پیش‌بینی شده در جدول مقابل، معیارهای Accuracy، Precision، Recall و Specificity را محاسبه کنید.

Label Predicted	Label Actual	ID Instance
+	+	۱
+	+	۲
+	-	۳
-	-	۴
+	+	۵
-	+	۶
+	-	۷

پاسخ:

در ابتدا ماتریس درهم‌ریختگی (Confusion Matrix) مربوط به این مدل را رسم می‌کنیم:

پیش‌بینی

-	+	
۱ = FN	۳ = TP	+
۱ = TN	۲ = FP	-

واقعی

حال معیارها را به دست می‌آوریم:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} = \frac{4}{7} \approx 0.5714$$

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{3}{5} = 0.6$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{3}{4} = 0.75$$

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}} = \frac{1}{3} \approx 0.3333$$

سوال ۳

با استفاده از روش KNN وزن‌دار (نزدیک‌ترین همسایه و $k = 3$ و استفاده از فاصله اقلیدسی) برچسب نمونه تست ($A = 1, B = 1, C = 1$) را به دست آورید.

پاسخ:

همان‌طور که مشخص است، در دیتاست ما در Instance اول، دقیقاً رکورد مورد نظر یعنی $(A = 1, B = 1, C = 1)$ موجود است که کلاس آن مثبت (+) می‌باشد. از آنجا که این رکورد از قبل در مجموعه داده موجود است، نیازی به محاسبه مجدد فواصل نیست و کلاس آن مستقیماً مشخص است. لذا کلاس پیش‌بینی‌شده برای این نمونه همان مثبت (+) خواهد بود.

سوال ۴

الف) اگر در یک مسئله دسته‌بندی ۴ کلاسه، یک مدل درخت تصمیم آموزش دهیم و دقت مدل با در نظر گرفتن معیار AUC برابر ۳۵ درصد باشد، آیا این مدل برای استفاده در الگوریتم AdaBoost مناسب است؟ در این مورد توضیح دهید.

ب) فرض کنید ۷ نمونه داده‌ای داریم و خروجی دسته‌بند M در مرحله اول الگوریتم AdaBoost به صورت جدول زیر باشد. آنگاه میزان خطای M و همچنین وزن مدل در مرحله فعلی و وزن آپدیت‌شده‌ی هر کدام از نمونه‌ها را محاسبه کنید.

Label Predicted	Label Actual	ID Instance
-	+	۱
+	+	۲
-	-	۳
+	-	۴
-	+	۵
+	+	۶
-	-	۷

پاسخ الف:

همان‌طور که می‌دانیم، AdaBoost یک الگوریتم مبتنی بر روش Boosting است. در این روش، دقت مدل پایه (ضعیف) باید حداقل کمی بهتر از مدل تصادفی (رندوم) باشد. در یک دسته‌بندی متوازن، این مقدار معادل $AUC \approx 0.5$ است. از آنجا که دقت این مدل برابر با $AUC = 0.35$ است، عملکرد آن حتی از حدس تصادفی نیز بدتر است. بنابراین، این مدل به‌خودی‌خود انتخاب مناسبی برای پایه‌ی الگوریتم نیست، مگر آنکه ابتدا با روش‌هایی بهبود یابد تا شرط اولیه حداقل دقت را برآورده کند.

پاسخ ب:

در ابتدا یک وزن اولیه برابر برای تمامی نمونه‌ها در نظر گرفته می‌شود:

$$W_i = \frac{1}{7} \approx 0.1428$$

با توجه به جدول، پیش‌بینی برای نمونه‌های ۱، ۴ و ۵ اشتباه بوده است (۳ خطا از ۷ نمونه). لذا خطای وزن‌دار

برای دور اول عبارت است از:

$$err_1 = \frac{3}{7} \approx 0.4286$$

چون مقدار خطا کمتر از 0.5 است، حلقه ادامه می‌یابد. وزن دسته‌بند (Classifier Weight) طبق فرمول زیر محاسبه می‌شود:

$$\alpha = \frac{1}{2} \ln \left(\frac{1 - err}{err} \right) = \frac{1}{2} \ln \left(\frac{1 - \frac{3}{7}}{\frac{3}{7}} \right) = \frac{1}{2} \ln \left(\frac{\frac{4}{7}}{\frac{3}{7}} \right) = \frac{1}{2} \ln \left(\frac{4}{3} \right) \approx 0.1438$$

در ادامه، اوزان را به‌روزرسانی می‌کنیم. برای نمونه‌های درست پیش‌بینی‌شده:

$$W_{\text{correct}} \leftarrow W_i e^{-\alpha} = \left(\frac{1}{7} \right) \times (0.4286)^{-0.14} \approx 0.12$$

برای نمونه‌های غلط پیش‌بینی‌شده:

$$W_{\text{incorrect}} \leftarrow W_i e^{\alpha} = \left(\frac{1}{7} \right) \times (0.4286)^{0.14} \approx 0.16$$

برای نرمال‌سازی، ابتدا مجموع اوزان جدید را محاسبه می‌کنیم ($S = 3(0.16) + 4(0.12) = 0.96$):

• وزن نهایی برای داده‌های اشتباه:

$$W_{\text{incorrect_final}} = \frac{0.16}{0.96} \approx 0.166$$

• وزن نهایی برای داده‌های درست:

$$W_{\text{correct_final}} = \frac{0.12}{0.96} = 0.125$$