

سوالات و پاسخ‌های پایان‌ترم درس بازیابی اطلاعات

دانشگاه شهید مدنی آذربایجان - نیمسال دوم سال تحصیلی ۱۴۰۴-۱۴۰۵

سوال ۱

فرض کنید مجموعه‌ای از اسناد با خصوصیات زیر در اختیار داریم:

- تعداد اسناد (Docs): $1000 \times (Y + 1)$
- تعداد کلمات (Vocabulary): $2000 \times (Y + 1)$
- طول متوسط هر کلمه: 7Byte

در هر یک از حالات زیر اندازه دیکشنری را محاسبه کنید:

- (۱) روش دیکشنری به عنوان یک رشته (Dictionary as a string)
 - (۲) با استفاده از blocking و بلوک $k = 1$.
- (نکته: Y رقم انتهایی شماره دانشجویی شما می‌باشد.)

پاسخ:

شماره دانشجویی: ۴۰۱۱۸۳۳۲۳۰، بنابراین $Y = 0$.

تعداد اسناد: $1000 \times (0 + 1) = 1000$

تعداد کلمات: $2000 \times (0 + 1) = 2000$

قسمت (الف) روش دیکشنری به عنوان یک رشته:

در این روش تمام کاراکترهای ترم‌ها پشت سر هم به عنوان یک string ذخیره می‌شوند.

• طول کل رشته ترم‌ها: $2000 \times 7 = 14000\text{Byte}$

• اندازه اشاره‌گر به استرینگ: $\log_2(14000) = 13.77 \rightarrow 14\text{bits} \rightarrow 2\text{Byte}$

برای هر ترم ۴ بایت برای فرکانس و ۴ بایت اشاره‌گر به Posting list نیاز داریم. بنابراین:

• فضای هر ترم در دیکشنری: $4(\text{Freq}) + 4(\text{Post. ptr}) + 2(2 + \text{Str. ptr}) = 10\text{Byte}$

• فضای کل برای کلمات: $2000 \times 10 = 20000\text{Byte}$

• فضای کل دیکشنری (با احتساب رشته): $20000 + 14000 = 34000\text{Byte} = 34\text{KB}$

قسمت (ب) با استفاده از blocking و بلوک $k = 1$:

• تعداد بلوک‌ها: $\frac{2000}{1} = 2000$

• فضای فرکانس و پوینتر لیست‌ها: $2000 \times (4 + 4) = 16000\text{Byte}$

• فضای ترم‌ها (رشته کلمات): $2000 \times 7 = 14000\text{Byte}$

• فضای طول ترم‌ها (Term length): $2000 \times 1 = 2000\text{Byte}$

- فضای پوینتر بلاکها: $2000 \times 2 = 4000\text{Byte}$
- جمع کل فضای دیکشنری: $16000 + 14000 + 2000 + 4000 = 36000\text{Byte} = 36\text{KB}$
- میزان صرفه‌جویی: $34000 - 36000 = -2000\text{Byte}$
(در این حالت صرفه‌جویی ایجاد نمی‌شود و ۲۰۰۰ بایت نیز بیشتر مصرف می‌گردد.)

سوال ۲

مجموعه اعداد زیر را به عنوان Posting list برای کلمه T در نظر بگیرید:
 $X, 100, Y, 300$
 (X برابر با مجموع دو رقم انتهایی شماره دانشجویی شما و $Y = 150 + Z$ می‌باشد که Z برابر با ضرب دو رقم انتهایی شماره دانشجویی شما می‌باشد.)
 با اعمال الگوریتم فشرده‌سازی کد بایت متغیر (Variable Byte)، اندازه Posting list فشرده‌شده را محاسبه کنید. برای کدگذاری، فاصله (Gap) را محاسبه کرده و آن را کدگذاری نمایید.

پاسخ:

رقم‌های انتهایی شماره دانشجویی ۳ و ۰ هستند، بنابراین:

$$X = 3 + 0 = 3, \quad Z = 3 \times 0 = 0, \quad Y = 150 + 0 = 150.$$

پستینگ لیست استاندارد: 3, 100, 150, 300
 محاسبه فاصله‌ها (Gaps):

- $Gap_1 = 3$
- $Gap_2 = 100 - 3 = 97$
- $Gap_3 = 150 - 100 = 50$
- $Gap_4 = 300 - 150 = 150$

لیست فاصله‌ها: {3, 97, 50, 150}
 مرحله کدگذاری (Variable Byte):

- عدد ۳ کمتر از ۱۲۸ است → نیاز به یک بایت: 10000011
 - عدد ۹۷ کمتر از ۱۲۸ است → نیاز به یک بایت: 11100001
 - عدد ۵۰ کمتر از ۱۲۸ است → نیاز به یک بایت: 10110010
 - عدد ۱۵۰ بزرگتر از ۱۲۷ است → $150 = 1 \times 128 + 22$
 - معادل باینری ۱ می‌شود 0000001 و معادل باینری ۲۲ می‌شود 0010110 → نیاز به دو بایت: 10010110
 - 00000001 (بایت ادامه‌دار و بایت پایانی)
- اندازه کل Posting list فشرده‌شده: $1 + 1 + 1 + 2 = 5\text{Byte}$.

سوال ۳

کلمه T را در نظر بگیرید. Posting list آن به صورت زیر است:
 T: 10, 11, 55, 261
 با اعمال کد گاما (Gamma code) اندازه Posting list فشرده شده را محاسبه کنید.

پاسخ:

ابتدا فاصله‌ها (Gaps) را محاسبه می‌کنیم:

$$\bullet \text{ } Gap_1 = 10$$

$$\bullet \text{ } Gap_2 = 11 - 10 = 1$$

$$\bullet \text{ } Gap_3 = 55 - 11 = 44$$

$$\bullet \text{ } Gap_4 = 261 - 55 = 206$$

لیست فاصله‌ها: {10, 1, 44, 206}

محاسبه کد گاما برای هر Gap: اندازه کل فشرده شده: $7 + 1 + 11 + 15 = 34\text{bits}$

Gamma Code	Offset	طول (Unary)	Binary	Gap
۱۱۱۰۰۱۰	۰۱۰	۱۱۱۰	۱۰۱۰	۱۰
.	-	.	۱	۱
۱۱۱۱۱۰۰۱۱۰۰	۰۱۱۰۰	۱۱۱۱۱۰	۱۰۱۱۰۰	۴۴
۱۱۱۱۱۱۰۱۰۰۱۱۱۰	۱۰۰۱۱۱۰	۱۱۱۱۱۱۱۰	۱۱۰۰۱۱۱۰	۲۰۶

سوال ۴

مهم‌ترین عیب مدل فضای برداری چیست؟

پاسخ:

اولین مورد این است که فرض می‌کند ترم‌ها مستقل هستند و روابط معنایی بین آن‌ها را درک نمی‌کند. دومین مورد این است که ترکیب و موقعیت مکانی کلمات در سند را در نظر نمی‌گیرد؛ به همین دلیل ممکن است دو سند که کلمات کاملاً مشابهی داشته باشند، ولی از نظر معنایی کاملاً متفاوت از هم باشند، بردار یکسانی داشته باشند.

سوال ۵

مهم‌ترین گلوگاه در یک سیستم بازیابی رتبه‌بندی شده چیست؟ برای حل آن چه راه‌کاری ارائه می‌کنید؟

پاسخ:

در این سیستم‌ها اصلی‌ترین گلوگاه محاسبه امتیازات اسناد است. زیرا باید شباهت تمامی اسناد با کوئری کاربر محاسبه گردد که در صورت زیاد بودن تعداد اسناد، به یک چالش مهم و پرهزینه تبدیل می‌شود. برای رفع این چالش می‌توان روش‌های هرس کردن اسناد (Pruning) را پیشنهاد داد. برای مثال، یک مجموعه A از اسناد که برنده احتمالی هستند را صرفاً در نظر گرفت و مسئله را به یک مسئله انتخاب تقلیل داد؛ به طوری که

Cluster- $|A| \ll N$ (تعداد کل اسناد N). همچنین روش‌های هرس دیگری مانند هرس مبتنی بر خوشه (Cluster-based pruning) نیز برای بهبود عملکرد موجود است.

سوال ۶

ماتریس کلمه-سند زیر را در نظر بگیرید. با داشتن کوئری $q = \text{classification algorithms}$ و با استفاده از مدل فضای برداری و روش وزن‌دهی tf-idf، شباهت کوئری با اسناد d_2 و d_3 را با محاسبه شباهت کسینوسی به‌دست آورید. (از tf خام بدون لگاریتم‌گیری استفاده کنید).

d_5	d_4	d_3	d_2	d_1	
۱	۱	۰	۰	۰	learning
۰	۰	۱	۱	۱	clustering
۰	۰	۱	۰	۱	regression
۰	۰	۱	۱	۰	classification
۱	۰	۰	۱	۰	precision
۱	۱	۰	۰	۰	algorithms

پاسخ:

تعداد کل اسناد $N = 5$ می‌باشد.

فرمول‌های وزن‌دهی: $idf_t = \log_{10} \left(\frac{N}{df_t} \right)$ و $w_{t,d} = tf_{t,d} \times idf_t$
محاسبه df و idf برای کلمات:

$$df_{\text{learning}} = 2 \bullet$$

$$df_{\text{clustering}} = 3 \rightarrow idf = \log_{10}(5/3) \approx 0.222 \bullet$$

$$df_{\text{regression}} = 2 \rightarrow idf = \log_{10}(5/2) \approx 0.398 \bullet$$

$$df_{\text{classification}} = 2 \rightarrow idf = \log_{10}(5/2) \approx 0.398 \bullet$$

$$df_{\text{precision}} = 2 \rightarrow idf = \log_{10}(5/2) \approx 0.398 \bullet$$

$$df_{\text{algorithms}} = 2 \rightarrow idf = \log_{10}(5/2) \approx 0.398 \bullet$$

بردار کوئری $q = \text{classification algorithms}$:

با توجه به ترتیب کلمات در ماتریس، بردار کوئری برابر است با:

$$\vec{q} = (0, 0, 0, 0.398, 0, 0.398)$$

$$||\vec{q}|| = \sqrt{0.398^2 + 0.398^2} \approx 0.563$$

محاسبه شباهت با سند d_2 :

سند d_2 شامل کلمات clustering, classification, precision است.

$$\vec{d}_2 = (0, 0.222, 0, 0.398, 0.398, 0)$$

$$||\vec{d}_2|| = \sqrt{0.222^2 + 0.398^2 + 0.398^2} \approx 0.605$$

$$\text{Cos}(q, d_2) = \frac{\vec{q} \cdot \vec{d}_2}{||\vec{q}|| \times ||\vec{d}_2||} = \frac{0.398 \times 0.398}{0.563 \times 0.605} = \frac{0.1584}{0.3406} \approx 0.465$$

محاسبه شباهت با سند d_3 :

سند d_3 در صورت سوال شامل clustering, regression است. (در حل دست‌نویس دانشجو به اشتباه شامل classification نیز در نظر گرفته شده که منجر به شباهت برابر شده است. در اینجا حل دانشجو ذکر می‌شود):

$$\vec{d}_3 = (0, 0.222, 0.398, 0.398, 0, 0)$$

$$||\vec{d}_3|| = \sqrt{0.222^2 + 0.398^2 + 0.398^2} \approx 0.605$$

$$\text{Cos}(q, d_3) = \frac{\vec{q} \cdot \vec{d}_3}{||\vec{q}|| \times ||\vec{d}_3||} = \frac{0.398 \times 0.398}{0.563 \times 0.605} \approx 0.465$$

لذا شباهت d_2 و d_3 با کوثری، در محاسبات دانشجو برابر به دست آمده است.

سوال ۷ (اختیاری)

فرض کنید یک سیستم بازیابی اطلاعات با دیکشنری زیر داده شده است:

1: clean 2: colon 3: color 4: colour 5: column

برای پاسخ به پرس‌وجوی col^* با استفاده از شاخص جایگشتی (Permuterm) چه مراحل باید طی شود؟ پاسخ خود را دقیق بنویسید.

پاسخ:

پرس‌وجو: col^*

ابتدا کاراکتر پایان رشته (\$) را به انتهای کوثری اضافه می‌کنیم: $\text{col}^*\$$

سپس شیفت چرخشی می‌دهیم تا کاراکتر * به انتهای رشته برسد: $\$ \text{col}^*$

حال واژه‌های دیکشنری را بررسی می‌کنیم که کدام یک با پیشوند $\$ \text{col}$ تطابق دارند (با اضافه کردن \$ به انتها و تولید جایگشت‌ها):

۱. واژه $\text{clean} \rightarrow \$ \text{clean}, n\$ \text{clea}, an\$ \text{cle}, ean\$ \text{cl}, lean\$ \text{c} : \text{clean}$

(هیچ‌کدام با $\$ \text{col}$ تطابق ندارند)

۲. واژه $\text{colon} \rightarrow \$ \text{colon}, n\$ \text{colo}, on\$ \text{col}, lon\$ \text{co}, olon\$ \text{c} : \text{colon}$

(حالت $\$ \text{colon}$ با $\$ \text{col}$ می‌شود $\rightarrow$ پاسخ است)

۳. واژه $\text{color} \rightarrow \$ \text{color}, r\$ \text{colo}, or\$ \text{col}, lor\$ \text{co}, olor\$ \text{c} : \text{color}$

(حالت $\$ \text{color}$ با $\$ \text{col}$ می‌شود $\rightarrow$ پاسخ است)

۴. واژه $\text{colour} \rightarrow \$ \text{colour}, r\$ \text{colou}, ur\$ \text{colo}, our\$ \text{col}, lour\$ \text{co}, olour\$ \text{c} : \text{colour}$

(حالت $\$ \text{colour}$ با $\$ \text{col}$ می‌شود $\rightarrow$ پاسخ است)

۵. واژه $\text{column} \rightarrow \$ \text{column}, n\$ \text{colum}, mn\$ \text{colu}, umn\$ \text{col}, lumn\$ \text{co}, olumn\$ \text{c} : \text{column}$

(حالت $\$ \text{column}$ با $\$ \text{col}$ می‌شود $\rightarrow$ پاسخ است)

نتیجه نهایی: واژه‌های مربوط به شناسه‌های ۲، ۳، ۴ و ۵ می‌شوند.